ДЗ5 - RL

Qwen3.5-2B, одна A100 80 ГБ, BF16, seed 42. LoRA r=16, α=32, dropout=0. TRL 1.16.0, Transformers 5.9.0, vLLM 0.22.0+cu129. Четыре генерации на промпт, два промпта на шаг, LR 5×10^{-6}, cosine, β=0,02, лимит rollout 512 токенов.

ToolACE: 11 300 исходных диалогов, три дубликата удалены, 821 диалог отклонен при разборе. Деление 90/10. В train 10 432 примера: 4 909 одиночных вызовов, 3 688 параллельных и 1 835 без вызова. Validation — 1 139 примеров. Медиана длины train-промпта 696 токенов, p95 — 1 399. Исключено 11 длинных train-промптов.

Чекпойнт выбирался каждые 15 шагов на 32 фиксированных примерах ToolACE по среднему strict accuracy для call и no-call. LoRA объединялся с исходными весами. BFCL: 350 примеров, исходный evaluator и токенизатор, thinking выключен, температура 0, максимум 1024 новых токена. Overall — среднее пяти групп.

BFCL

Запуск	Overall	Simple	Multiple	Parallel	Parallel multiple	Irrelevance	Выбранный шаг
base	68.93%	68.00%	78.67%	56.00%	80.00%	62.00%	—
rl1_grpo_strict	68.93%	66.00%	78.67%	54.00%	80.00%	66.00%	15
rl2_grpo_shaped	68.93%	68.00%	80.67%	56.00%	80.00%	60.00%	30
rl3_drgrpo_shaped	68.40%	68.00%	80.00%	56.00%	80.00%	58.00%	15
rl2_grpo_shaped_90	69.07%	68.00%	79.33%	58.00%	80.00%	60.00%	30

Два GRPO на 30 шагах повторили Overall baseline. Dr. GRPO уступил 0,53 п. п. Запуск на 90 шагов дал +0,13 п. п., но по validation выбран 30-й шаг (72,92%).

Гипотезы экспериментов

- RL-1 (GRPO, strict, 30 шагов): точное совпадение должно поощрять правильные вызовы целиком, но бинарная награда может часто совпадать внутри группы.

- RL-2 (GRPO, shaped, 30 шагов): частичный балл должен увеличить долю групп с различающимися наградами.

- RL-3 (Dr. GRPO, shaped, 30 шагов): фиксированная нормировка loss и отключение деления advantage на стандартное отклонение могут изменить вклад групп разной длины и сложности.

- RL-2 (GRPO, shaped, 90 шагов): большее количество шагов может улучшить качество.

Ответы на вопросы задания

1. Почему выбрали такую награду?

Для корректного вызова важны имя функции и все аргументы. Strict дает 1 за полное совпадение мультимножества вызовов и аргументов и 0 за ошибку. Эта награда служит точкой отсчета. Shaped дает частичный сигнал при правильном выборе функции или части аргументов: 0,5 × strict + 0,2 × F1 имен + 0,3 × оценка аргументов с однозначным сопоставлением вызовов. Для no-call награду получает непустой корректный ответ без вызова. Пустой, обрезанный или невалидный ответ получает 0.

Если ожидается f(x=1, y=2), а модель вызвала f(x=1), то strict = 0, F1 имени = 1, F1 аргументов = 2/3 и shaped = 0,40. При полном совпадении обе награды равны 1.

2. Какое изменение сильнее всего повлияло на качество? Как отделили его эффект?

По BFCL Overall самое большое наблюдаемое изменение между сопоставимыми запусками — снижение с 68,93% у RL-2 до 68,40% у RL-3 (−0,53 п. п.). Оба запуска использовали shaped, один seed и 30 шагов. При переходе на Dr. GRPO одновременно поменялись нормировка loss и масштабирование advantage.

Эффект награды сравнивали на RL-1 и RL-2, где алгоритм и шаги совпадали. Overall остался 68,93%, хотя Multiple вырос на 2 п. п., а Irrelevance снизился на 6 п. п. Про устнойчивый эффект говорить нельзя, так как всего один seed и разницы в Overall небольшие.

3. Совпадает ли рост награды с ростом BFCL? Что объясняет расхождение?

Награды колеблются от шага к шагу и не показывают устойчивого роста. У RL-2 доля групп с одинаковой наградой снизилась с 75,0% до 68,3% относительно RL-1, но BFCL Overall остался прежним. Доля таких групп показывает частоту сигнала, а не величину награды. Кроме того, strict и shaped используют разные шкалы, поэтому их средние напрямую сравнивать нельзя.

Награда измеряется на меняющихся группах генераций ToolACE, а BFCL проверяет фиксированные примеры по правилу 0 или 1. Например, shaped дает 0,40 за вызов с пропущенным аргументом, если функция и часть аргументов верны. В BFCL пропуск обязательного аргумента может обнулить результат всего примера.

4. Что происходит с Advantage, если все ответы на запрос получают одинаковую награду?

После вычитания среднего advantage каждого ответа в группе равен нулю. Это верно и при нормировке на стандартное отклонение с добавлением ε, и без нее. Группа не дает градиентного сигнала от награды. При $\beta > 0$ в loss остается возможный вклад KL-регуляризации.

5. Какие ошибки остались у лучшей модели?

Среди запусков итоговой таблицы наивысший Overall у RL-2 с 90 шагов (69,07%, чекпойнт 30-го шага). В сохраненных предсказаниях есть три типа ошибок:

- **Simple, simple_241, пропущенный вызов.** Модель ответила «Abraham Lincoln» текстом. BFCL ожидал вызов US_President_During_Event с event="Civil War".

- **Live Irrelevance, live_irrelevance_142-13-8, лишний вызов.** Модель вызвала ControlAppliance.execute, хотя Baseline в этом примере воздержался.

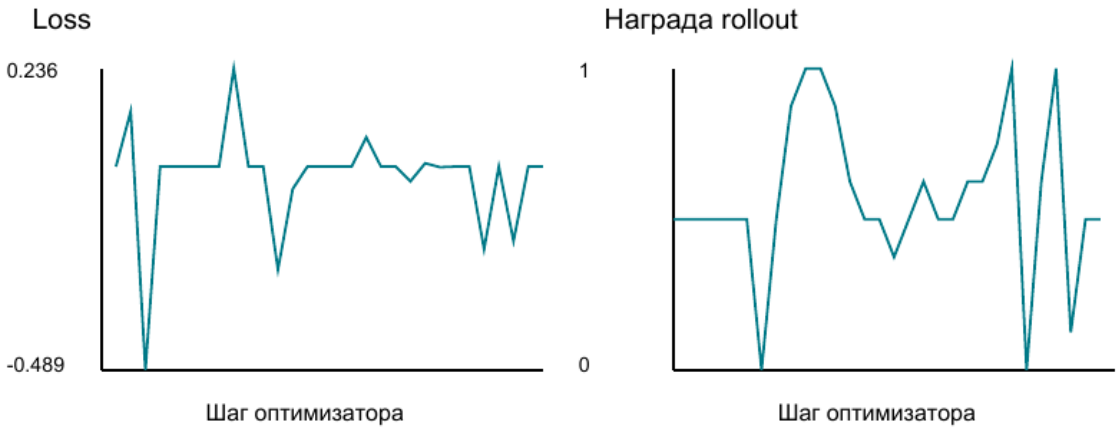
- **Live Multiple, live_multiple_793-174-7, неверный аргумент.** Модель выбрала Homes_2_ScheduleVisit, но передала дату 2024-03-14 вместо 2023-03-14.

В других примерах RL-2 исправил пропуски baseline: в multiple_138 вызвал legal_case.fetch с корректными аргументами, а в parallel_61 выполнил все три вызова math.hypot.

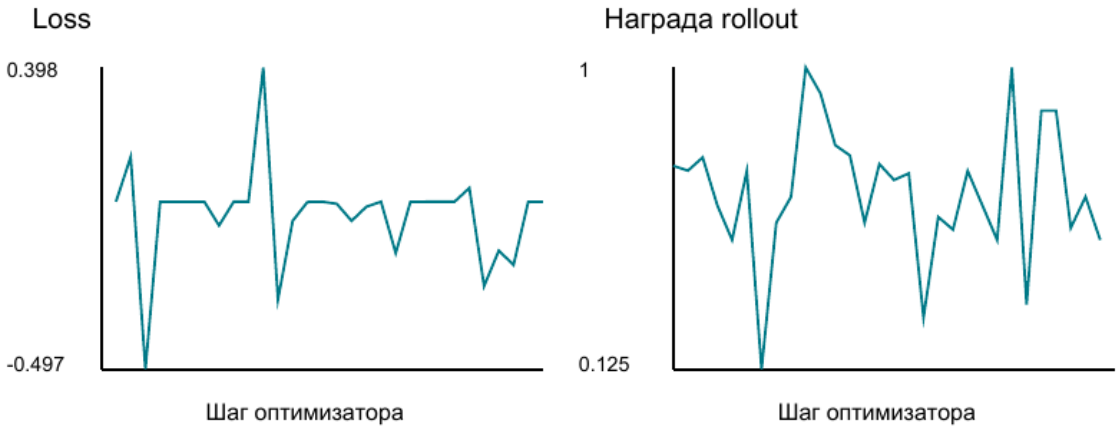
Динамика обучения

RL-1 и RL-2

RL-1 · Strict · 30 шагов, выбран 15. 9.8 мин, 23.70 ГиБ allocated. Группы без разброса награды 75.0%.



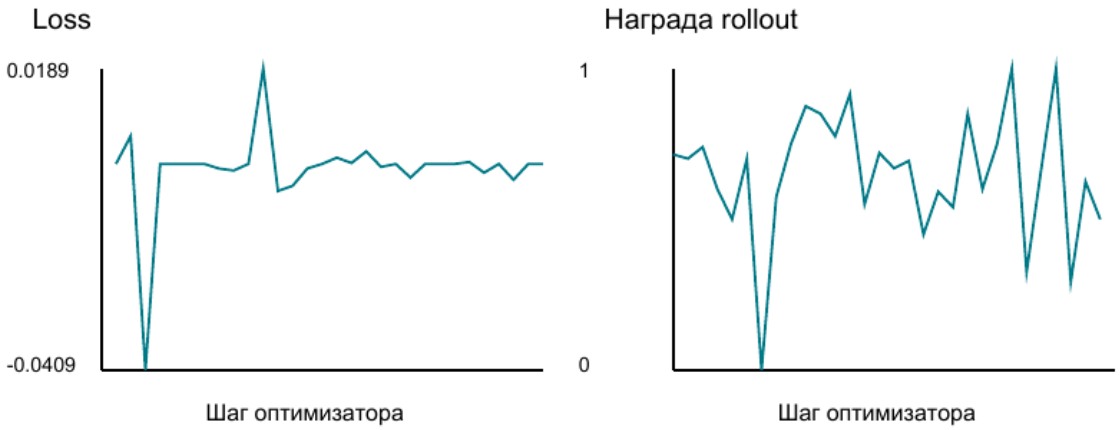
RL-2 · Shaped · 30 шагов, выбран 30. 8.5 мин, 23.68 ГиБ allocated. Группы без разброса награды: 68.3%.



Динамика обучения

RL-3 и RL-2 на 90 шагах

RL-3 · Dr. GRPO · 30 шагов, выбран 15. 7.8 мин, 23.71 ГиБ allocated. Группы без разброса награды: 63.3%.



RL-2 · 90 шагов · 90 шагов, выбран 30. 24.3 мин, 23.71 ГиБ allocated. Группы без разброса награды: 64.4%.

